

S2CHANGE: Desenvolvimento de mapas de perdas recentes de floresta e mato em Portugal derivados de imagens de satélite

Contrato N.º 3044 de cooperação entre a Direção Geral do Território e o Instituto Superior de Agronomia (Procedimento CEXC/2152/2023)

Índice

Descrição do projeto e referências	1
Principais objetivos	2
Base de dados de referência	2
Aplicação informática em cluster HPC	4
Mapas de perdas de vegetação	6

Descrição do projeto e referências

Enquadramento: O contrato tem enquadramento no subprojecto «P1.5- Dados de deteção remota para a gestão florestal» (DRFloresta) do projeto Agenda Transform (Agenda para a transformação digital das cadeias de valor florestais numa economia portuguesa mais resiliente e hipocarbónica), apoiado pelo Plano de Recuperação e Resiliência (PRR), sob o cabimento n.º CI42300913 e compromisso n.º CI52301229

Objetivo: O contrato tem por objeto a realização de atividades de investigação e desenvolvimento (I&D) para o desenvolvimento de metodologias eficazes à escala nacional e eficientes a nível computacional para a criação sistemática de um produto nacional em formato vetorial de delimitação de manchas superiores a 0.5 ha de perda recente de floresta e mato com base em análise automática de imagens de satélite

- Gestor do Contrato: Hugo Costa, DGT
- Responsável pela execução: Manuel Campagnolo, CEF, DCEB, ISA

Data de início: contrato assinado a 20 de outubro de 2023; inicial data de vigência: 19/10/2025; alterado por aditamento para: 30/06/2026

Repositório GutHub do projeto:

https://github.com/S2change/vegetation_loss/blob/main/README.md

Principais objetivos

Os três principais objetivos do contrato são:

1. Construção de uma base de dados de referência (Tarefa 2) para o território de Portugal Continental com exemplos de ocorrências de perdas da vegetação em floresta e mato. Cada ocorrência descrita pela localização, intervalo de tempo -- contemplando incerteza temporal através de um par data mínima, data máxima -- em que a perda de vegetação ocorreu; tipo de alteração (no mínimo deverá ter os rótulos “Corte” ou “Fogo”)
2. Desenvolvimento de uma aplicação informática que possa ser integrada na cadeia de produção da DGT, implementada num cluster HPC e articulada com outras cadeias de produção baseadas em séries temporais de imagens Sentinel-2 (Tarefa 3 e Tarefa 4)
3. Criação e validação de produto nacional de delimitação de manchas vectoriais superiores a 0.5 ha de perda recente de floresta e mato, com uma periodicidade de pelo menos dois meses (Tarefa 3) e identificação sistemática do agente causador das perdas recentes de floresta e mato delimitadas nesse produto (Tarefa 4).

Base de dados de referência

Uma parte significativa dos recursos do projeto foram dedicados à aquisição de um conjunto de dados de referência representativo e fiável. Os métodos e código estão disponíveis em https://github.com/S2change/vegetation_loss/tree/main/data_info/reference_data.

Para esse processo foi desenvolvido uma metodologia semi-automatizada. O algoritmo de detecção de alterações CCD (Continuous Change Detection) foi aplicado ao nível do pixel em séries temporais Sentinel-2 e permitiu identificar datas prováveis de perdas de vegetação que foram depois confirmadas por visualização manual de imagens Sentinel-2 e outras fontes de informação. O módulo pyCCD para essa análise semi-automática desenvolvido no quadro do projeto está descrito e disponível em https://github.com/S2change/vegetation_loss/tree/main/scripts/pyccd dos dados do Sentinel-2.

Existem dois conjuntos de dados referência:

1. Uma base de dados de referência harmonizada de polígonos áreas de cortes e áreas ardidas. A parte referente às áreas ardidas é fornecida pelos mapas oficiais de áreas ardidas do INCF (“Territórios ardidos” do GeoCatálogo: https://geocatalogo.icnf.pt/catalogo_tema5.html). A parte referente às áreas de corte provém de uma combinação de fontes. Todas as fontes de dados de referência estão descritas em https://github.com/S2change/vegetation_loss/tree/main/data_info/reference_data/Harmonized.

Especificamente, os conjuntos de dados individuais que foram compilados e harmonizados são:

a) NVG: baseado em informação do NVG, complementado por verificação semiautomática de datas a partir de uma análise CCD de séries temporais do Sentinel-2 e confirmado visualmente -- ver

https://github.com/S2change/vegetation_loss/tree/main/data_info/reference_data/NVG

b) ICNF: mapas oficiais de áreas ardidas do ICNF

c) BDR-TNE-300: base de dados de polígonos DGT para 300 áreas circulares no mosaico T29TNE

d) BDR-TNE-300-Expandido: expansão de um subconjunto do anterior para polígonos de 1 km por 1 km

O conjunto de dados harmonizado (incluindo todos os conjuntos de dados individuais) contém cerca de 11.000 entidades geográficas do tipo polígono (features), abrangendo o período de 2017 a 2023. Cada “feature” tem um intervalo de incerteza temporal associado [data0, data1], onde, com elevada confiança, ocorreu perda de vegetação. A deteção de alterações foi guiada por dados de campo e por uma análise automática baseada no algoritmo CCD, sendo posteriormente confirmadas visualmente.

Os detalhes sobre os exemplos de "cortes rasos" e outras perdas de vegetação em plantações nos dados de referência são fornecidos em

a)

https://github.com/S2change/vegetation_loss/blob/main/data_info/reference_data/Harmonized/NVG/NVG.md; e em

b)

https://github.com/S2change/vegetation_loss/blob/main/data_info/reference_data/NVG/readme.md.

2. Chips visuais de 4 km por 4 km (vchips). Estes foram criados em áreas em torno de “features” do conjunto de dados harmonizado e foram interpretados visualmente a partir de imagens Sentinel-2 e outras fontes. Este conjunto de dados “vchips” está descrito em https://github.com/S2change/vegetation_loss/blob/main/data_info/reference_data/vchips_for_training/readme.md.

Os chips visuais foram usados para treinar, validar e testar (com uma amostra de vchips independente) o modelo de aprendizagem profunda que é incorporado na aplicação informática em cluster HPC descrita abaixo.

Quando novos mapas forem produzidos e validados, este conjunto de dados poderá ser facilmente expandido e utilizado para ajustar e melhorar o modelo de aprendizagem profunda.

Aplicação informática em cluster HPC

O corrente projeto foi considerado como projeto-piloto na colaboração entre DGT e o LIP que opera o cluster HPC “INCD”, enquadrado no Centro Nacional de Computação Avançada (CNCA).

No quadro dessa colaboração foram desenvolvidos dois “pipelines” completos, desde a aquisição das imagens Sentinel-2 de refletância de superfície, até à produção dos mapas de perdas de vegetação em formato vetorial no cluster HPC.

Foram consideradas duas abordagens que tiram partido da paralelização computacional que pode ser implementada no Cluster HPC:

1. Processamento ao nível do pixel, em que o input é a série temporal de um índice (e.g. NDVI) calculado para cada data de aquisição de imagens Sentinel-2. O algoritmo CCD (continuous change detection) é então usado para determinar a data de alteração ou decidir que não há alteração. Combinando os resultados obtidos para todos os pixels, obtêm-se um mapa raster para o território com datas de alteração estimadas, que é então convertido para formato vetorial. O procedimento foi usado apenas para pixels em [DGT_mask](#), o que representa um conjunto de aproximadamente 500 M de pixels.
2. Processamento baseado em técnicas de “deep learning” usando redes convolucionais do tipo Unet que exploram o contexto espacial. Neste caso, o input é uma chip de 256 por 256 pixels, com um par de observações: um compósito temporal “antes” com 10 bandas e um compósito temporal “depois” com 10 bandas. Para explorar o paralelismo computacional, cada tile é dividida em blocos 10 km por 10 km, e cada bloco é dividido em “chips” de 2560 m por 2560 m. Cada bloco é associado a uma tarefa distinta no cluster HPC permitindo assim tirar partido do grande número de CPUs disponíveis no cluster (ver Figura 1). Dado que o cluster HPC não dispõe de momento de unidades GPU, foi selecionado um modelo de deep learning com apenas 10M de parâmetros (Efficientnet_b2) que pode ser executado em tempo útil em CPU.

Para os objetivos do projeto, a conclusão é que a abordagem baseada em “deep learning” é mais adequada pois produz mapas com maior precisão, é mais flexível em termos operativos e consome menos recursos. A estimativa do tempo de processamento em cluster HPC para criar o mapa de perdas de vegetação para Portugal Continental sobre um período de 2 meses (com aproximadamente 8 datas potenciais de alteração) é de aproximadamente 45 minutos.

Em traços muito gerais, os principais passos do pipeline baseado em técnicas de “deep learning” são:

1. Aquisição e pré-processamento para produção de ficheiros HDF5:
 - a. As imagens nativas de refletância de superfície Sentinel-2 são adquiridas pelo CNCA em formato geotiff de 16 bits, podendo existir mais do que um ficheiro

geotiff por dia. A cobertura de nuvens é estimada pelo Copernicus por mosaico e órbita, sem ter em conta a cobertura nacional específica.

- b. Os ficheiros geotiff são pré-processados para estimar a cobertura de nuvens e a filtragem de nuvens foi aplicada ao território português (NoData=65535).
 - c. Em seguida, os ficheiros geotiff são filtrados, possivelmente agregados por dia, e convertidos para o formato hdf5 para acelerar a leitura para processamento posterior. São filtrados com base na cobertura de nuvens estimada sobre o território português (PT_mask), sendo as imagens agregadas diárias descartadas se a cobertura de nuvens sobre PT_mask for superior a 60%.
Os detalhes deste processamento podem ser encontrados em https://github.com/S2change/vegetation_loss/blob/main/scripts/data_exploration/tifs_to_hdf5_to_tifs/CNCA_tifs_to_hdf5/readme.md
 - d. Os ficheiros HDF5 disponíveis no CNCA serão continuamente atualizados no CNCA com novas aquisições do Sentinel-2, seguindo o mesmo protocolo.
2. Para uma tile a ser processada, e para um intervalo temporal de análise, leitura do ficheiro HDF5 único para a tile e determinação das datas (D) potenciais de alteração a ser processadas, em função de parâmetros escolhidos pelo utilizador (ver Entregável 4.1 para detalhes).
 3. Para cada data, construir compósito temporal anterior a D (“antes”) com 10 bandas e uma compósito temporal posterior a D (“depois”) com 10 bandas. Estes são compostos pelos valores espectrais válidos (não NoData) em cada pixel para as datas D’ o mais próximo possível da data D.
 4. Criar chips espaciais de 256*256 (com sobreposição) e aplicar o modelo de “deep learning” classificação de perda de vegetação por aprendizagem profunda a cada chip. Isto gera um rótulo – 0 para fundo (sem alteração); 1 para “Cortes”; 2 para “Fogos”) ao nível do pixel para cada chip.
 5. Combinar os resultados para todas as datas analisadas e converter em formato vetorial: o output é um ficheiro Geopackage em que cada “feature” é uma área em que é detetada perda de vegetação, com uma data, e um rótulo (“Corte” ou “Fogo”)

O procedimento descrito acima deve ser muito eficiente para poder processar uma enorme quantidade de informação para cada data potencial analisada e deve poder tirar partido para paralelização que pode ser realizada no cluster HPC.

O processo é realizado com dois níveis de paralelismo para reduzir o tempo total de computação tirando partido da arquitetura multi-node e multi-core do cluster HPC:

1. Processamento das tiles em paralelo
2. Processamento de blocos de cada tile de 10 por 10 km com uma margem de sobreposição, sendo o processamento de cada bloco uma tarefa distribuída em paralelo pelos cores existentes, com a agregação dos outputs dos blocos realizada no final do processamento da tile.

Um aspeto a realçar é que a metodologia usada para a produção de mapas de perdas de vegetação permite uma utilização em tempo-quase-real, como previsto nos objetivos do

projeto. Dado que o classificador compara um compósito temporal “antes” e um “depois” para cada data D, o utilizador pode usar o pipeline para obter um mapa de perdas de vegetação recentes, no pressuposto que as imagens Sentinel-2 recentes tenham sido pré-processadas e adicionadas aos ficheiros hdf5. Assim, a criação de um produto bimestral como previsto nos objetivos, é realizada simplesmente escolhendo como argumentos da execução do pipeline os valores que definem o período pretendido (ver Entregável 4.1: Manual de Utilização Operacional).

Mapas de perdas de vegetação

A validação dos mapas de perdas de vegetação (ver Entregável 4.3) foi realizado de duas formas: ao nível das chips 256 por 256 derivadas da base de dados de referência e usadas para treino, validação e teste do modelo de aprendizagem profunda, e por comparação visual dos mapas finais com dados de referência.

A validação com chips de teste independentes para o modelo Efficientnet_b2 mostra que o modelo preditivo tem uma elevada precisão para "Fogos" (precision = 0,97; recall = 0,93; F1-score = 95%) e moderada para "Cortes" (precision = 0,71; recall = 0,57; F1-score = 63%) ao nível do pixel.

Para as manchas detetadas, os resultados para os chips de teste independentes sugerem que há omissão em 8% dos fogos e que 3% dos fogos correspondem a falsos alarmes. Para os cortes, as estimativas são de 23% de omissão e 22% de falsos alarmes.

Para os mapas nacionais produzidos para 2023-2024, a análise visual em comparação com os dados de referência sugere que as estimativas de precisão moderadas a elevadas descritas atrás são consistentes. A disponibilidade de um extenso conjunto de dados de referência permitirá estender os resultados da validação a áreas fora dos chips visuais de referência.

O conjunto de dados de referência pode ser facilmente expandido. Ou seja, o conjunto de chips visuais pode ser enriquecido para permitir um ajustamento adicional do modelo de aprendizagem profunda e uma melhoria da precisão. Estas alterações podem ser diretamente incorporadas no pipeline ISA_DGT_INCD_DL atual, bastando atualizar o ficheiro de pesos do modelo de aprendizagem profunda.

- S2 geotiffs
- DGT_mask
- PT_mask

- S2 geotiffs
- S2 omni_masks
- DGT_mask
- PT_mask

Comprimido e "chunked"
256*256 para otimizar acesso

Inputs:

paralelização
CLUSTER → NODO

bloco 10*10 km + buffer

paralelização

NODO → PROCESSADOR

chips 2560*2560 m




Figura 1: Diagrama que ilustra a pipeline da aplicação informática baseado em técnicas de “deep learning” implementada no cluster HPC do INCd