

Entregável 4.1. Código modular em Python para "benchmarking" de algoritmos de segmentação a integrar em PyCCDC. Estimativas de necessidades computacionais para processamento para o território de Portugal Continental com a frequência temporal de 2 meses

## Índice

|                                                                                                                                                   |   |
|---------------------------------------------------------------------------------------------------------------------------------------------------|---|
| 1. Introdução .....                                                                                                                               | 2 |
| 2. Estimativas de necessidades computacionais para o processamento do território de Portugal Continental com frequência temporal de 2 meses ..... | 2 |

## 1. Introdução

O presente entregável tem como objetivo o desenvolvimento de um código modular em Python para “benchmarking” de algoritmos de segmentação a integrar no PyCCDC. O foco principal será disponibilizar uma infraestrutura modular em Python capaz de detetar quebras na vegetação em séries temporais de imagens Sentinel-2, permitindo aplicar, testar e comparar diferentes algoritmos de segmentação — como métodos baseados em grafos, abordagens clássicas e técnicas de deep learning.

No presente momento, estão disponíveis dois scripts principais em Python que servem de base para este “benchmarking”:

- Um script simplificado que permite a criação de clusters de pixels ([https://github.com/S2change/vegetation\\_loss/blob/main/scripts/visualisations/raster\\_polygon\\_processing.py](https://github.com/S2change/vegetation_loss/blob/main/scripts/visualisations/raster_polygon_processing.py))
- Um script baseado em grafos que implementa uma abordagem modular e extensível ([https://github.com/S2change/vegetation\\_loss/blob/main/scripts/graphs/create\\_graph\\_from\\_parquet.py](https://github.com/S2change/vegetation_loss/blob/main/scripts/graphs/create_graph_from_parquet.py))

Além da componente de código, o relatório apresenta também uma estimativa das necessidades computacionais associadas ao processamento de imagens Sentinel-2 para o território de Portugal Continental, com uma frequência temporal de 2 em 2 meses. Esta estimativa baseia-se no histórico de processamento realizado entre 2017 e o final de 2024, fornecendo uma base sólida para a preparação de futuras execuções do PyCCDC.

## 2. Estimativas de necessidades computacionais para o processamento do território de Portugal Continental com frequência temporal de 2 meses

Os dados apresentados na Tabela 1 correspondem ao processamento realizado para o período de 2017 até ao final de 2024, incluindo assim vários ciclos bimestrais de análise. Este processamento histórico inclui exclusivamente as áreas de floresta e mato, permitindo que, futuramente, o PyCCD possa ser executado apenas a partir da data de início do último segmento identificado, evitando a necessidade de refazer todo o processamento desde o início. Este método reduz substancialmente os custos computacionais futuros.

| TILES            | N           | batch_size | (nodes, ntasks, cpus, ranks) | PROCESSING TIME        | CORES-MINUTES | Parquet size (GB) | core-minutes/pixel | HDFS size (GB) |
|------------------|-------------|------------|------------------------------|------------------------|---------------|-------------------|--------------------|----------------|
| T29SMD           | 14 701 306  | 10         | (5,96,1,480)                 | 09:43:04               | 279 872       | 1,91              | 0,01903722         | 54,5           |
| T29TNE           | 78 110 448  | 1000       | (5,96,1,480)                 | 35:47:01               | 1 030 576     | 9,92              | 0,01319383         | 197            |
| T29TNG           | 35 563 095  | 500        | (5,96,1,480)                 | 21:29:26               | 618 928       | 4,1               | 0,01740366         | 114            |
| T29TNF           | 55 404 126  | 1000       | (5,96,1,480)                 | 27:11:57               | 783 336       | 6,43              | 0,014138586        | 150            |
| T29SND           | 55 288 591  | 1000       | (5,96,1,480)                 | 24:07:01               | 694 568       | 4,29              | 0,012562592        | 139            |
| T29SMC           | 4 720 362   | 10         | (5,96,1,480)                 | 02:59:58               | 86 384        | 0,61              | 0,018300291        | 16,9           |
| T29SNB           | 43 415 866  | 500        | (5,96,1,480)                 | 18:52:29               | 543 592       | 5,45              | 0,012520584        | 113            |
| T29SNC           | 23 246 960  | 100        | (5,96,1,480)                 | 09:01:46               | 260 048       | 3,01              | 0,011186323        | 54,7           |
| T29SPC           | 9 175 988   | 50         | (5,96,1,480)                 | 05:58:45               | 172 200       | 1,31              | 0,018766372        | 33,6           |
| T29SPB           | 17 137 809  | 50         | (5,96,1,480)                 | 14:06:41               | 406 408       | 2,18              | 0,023714117        | 78             |
| T29SPD           | 15 613 476  | 50         | (5,96,1,480)                 | 06:47:57               | 195 816       | 2                 | 0,012541474        | 40,5           |
| T29TME           | 2 970 016   | 20         | (5,96,1,480)                 | 01:59:01               | 57 128        | 0,52              | 0,019234913        | 10,7           |
| T29TPE           | 50 968 649  | 1000       | (5,96,1,480)                 | 21:49:28               | 628 544       | 6                 | 0,012331973        | 126            |
| T29TPF           | 57 931 500  | 1000       | (5,96,1,480)                 | 20:33:46               | 592 208       | 3,52              | 0,010222556        | 121            |
| T29TPG           | 32 657 574  | 200        | (5,96,1,480)                 | 11:30:22               | 331 376       | 2,82              | 0,010146988        | 68,1           |
| T29TQF           | 2 775 492   | 10         | (5,96,1,480)                 | 01:56:02               | 55 696        | 0,363             | 0,02               | 10,7           |
| T29TQG           | 4 777 920   | 10         | (5,96,1,480)                 | 02:58:14               | 85 552        | 0,6025            | 0,0179057          | 16,6           |
|                  | 504 459 178 |            |                              | 220:47:16              | 6 822 232     | 55,04             |                    |                |
| Total (estimate) | 504 459 178 |            |                              | 220:47:16<br>(10 days) | 6 822 232     | 55,04             |                    | 1344,3         |

Tabela 1 – Recursos computacionais utilizados no processamento de séries temporais de imagens Sentinel-2 com o PyCCD, para as áreas de floresta e mato em Portugal Continental, no período de 2017 a 2024.

- Volume de dados: o processamento com o PyCCD abrange aproximadamente 504 milhões de pixels classificados como floresta ou mato no território de Portugal Continental, distribuídos por vários tiles.
- Configuração de processamento: o processamento é realizado com um cluster configurado com 5 nodes, 96 tarefas por node, totalizando 480 CPUs em paralelo.
- Tempo total: o processamento de todos os tiles demora cerca de 220 horas (aproximadamente 10 dias).
- Uso de recursos: são consumidos cerca de 6.8 milhões de cores-minutos para o processamento total.
- Tamanho dos dados: os ficheiros parquet gerados ocupam aproximadamente 55 GB, enquanto os ficheiros HDF5 totalizam cerca de 1344 GB (1.34 TB).